UNIVERSIDADE DE SÃO PAULO
Instituto de Ciências Matemáticas e da Computação - ICMC

Relatório Parcial: Exploração, Análise e Pré-Processamento de Dados

Grupo:
Arthur Araujo - 14651458
Arthur Filliettaz - 12532055
Leonardo Demore - 15674786

Relatório apresentado à disciplina SME0860 - Aprendizado de Máquina Aplicado a Problemas.

Professor: Prof. Dr. André Carlos Ponce de Leon Ferreira de Carvalho

São Carlos - SP
2026

Conjunto de Dados: Intoxicação Exógena

Resumo

Este relatório apresenta as etapas iniciais de extração, pré-processamento e análise exploratória de dados (EDA) referentes aos casos de Intoxicação Exógena notificados no Sistema de Informação de Agravos de Notificação (SINAN) entre os anos de 2021 e 2023. O objetivo desta etapa é preparar uma base de dados limpa e consistente para a futura aplicação de modelos de aprendizado de máquina.

1 Introdução

A intoxicação exógena é um problema de saúde pública significativo. O monitoramento desses casos é fundamental para o desenvolvimento de políticas de prevenção e resposta rápida. Para este projeto, utilizamos os dados públicos do SINAN, referentes aos anos de 2021 a 2023, visando entender o perfil epidemiológico das intoxicações e preparar os dados para modelagem preditiva. A escolha dos anos de 2021 a 2023 se dá por conta de alguns problemas que ocorriam ao tentar trabalhar com a base de dados inteira por conta de memória.

2 Coleta e Seleção dos Dados

A base de dados original foi extraída utilizando a biblioteca `pysus`, resultando em um *dataset* inicial robusto contendo 589.058 registros e 83 variáveis.

Para focar nas informações mais relevantes para o problema e reduzir a dimensionalidade, realizamos uma filtragem inicial, mantendo apenas 24 colunas essenciais. As variáveis selecionadas foram divididas nos seguintes grupos:

- **Dados Demográficos e Sociais:** `NU_IDADE_N` (Idade), `CS_SEXO` (Sexo), `CS_GESTANT` (Status de gestação), `CS_RACA` (Raça/Cor), `CS_ESCOL_N` (Escolaridade), `ID_OCUPA_N` (Ocupação) e `SIT_TRAB` (Situação no mercado de trabalho).
- **Dados da Exposição/Intoxicação:** `DT_NOTIFIC` (Data da notificação), `LOC_EXPO` (Local da exposição), `UF_EMP` e `MUN_EMP` (UF e Município da empresa), `AGENTE_TOX` (Agente tóxico), `VIA_1` (Via de exposição principal), `CIRCUNSTAN` (Circunstância da exposição), `TPEXP` (Tipo de exposição), `NUTEMPO` e `TPTEMPO` (Tempo decorrido).
- **Atendimento e Desfecho Clínico:** `DOENCA_TRA` (Doença relacionada ao trabalho), `TPATENDE` (Tipo de atendimento), `HOSPITAL` (Hospitalização), `DTINTERNA` (Data de internação), `CLASSI_FIN` (Classificação final), `EVOLUCAO` (Evolução do caso) e `DT_OBITO` (Data do óbito).

3 Pré-Processamento e Limpeza

Os dados em formato bruto apresentavam diversos desafios inerentes a registros de saúde pública, como inconsistências, valores nulos e tipagens incorretas. Para garantir a qualidade da análise exploratória e da futura modelagem preditiva, as seguintes etapas rigorosas de limpeza foram aplicadas:

- **Conversão de Tipos:** Inicialmente, identificamos que muitas colunas numéricas haviam sido importadas como texto. Forçamos a conversão dessas variáveis para formato numérico (tratando erros com `coerce`) e convertemos as colunas de tempo (`DT_NOTIFIC`, `DTINTERNA`, `DT_OBITO`) para o formato `datetime`.
- **Tratamento de Inconsistências Lógicas e *Outliers*:**
  - **Idades:** O SINAN utiliza um código específico na variável `NU_IDADE_N`, onde o primeiro dígito indica a unidade de tempo (4 para anos, 3 para meses, 2 para dias). Implementamos uma função `decode_idade` para extrair esses valores e padronizar toda a base em anos completos numa nova coluna (`IDADE_ANOS`). *Outliers* absurdos, como idades acima de 110 anos, foram convertidos para nulos (`NaN`).
  - **Sexo vs. Gestação:** Identificamos registros de pacientes do sexo masculino (`CS_SEXO = 'M'`) classificados com dados inválidos na coluna de gestação. Padronizamos essas entradas para o código de "Não se aplica".
  - **Caracteres Indesejados:** Utilizamos expressões regulares (*regex*) na coluna `NUTEMPO` para extrair exclusivamente os dígitos numéricos.
- **Mapeamento de Variáveis Categóricas:** Para facilitar a visualização durante a EDA, criamos cópias das colunas categóricas com o sufixo `_DESC`. Através de um dicionário referencial, mapeamos os códigos numéricos para suas descrições literais exatas (ex: na coluna `AGENTE_TOX`, o valor "1.0"tornou-se "Medicamento"). Obtemos esse mapeamento por meio desse PDF: PDF Intoxicação Exógena
- **Engenharia de Features (Criação de Variável-Alvo):** Observamos que a variável `DTINTERNA` apresentava cerca de 69,11% de valores nulos, o que clinicamente significa que a maioria dos pacientes não foi internada. Transformamos essa informação escassa em uma feature binária com um valor analítico maior chamada `INTERNADO` (onde 1 indica que houve internação e 0 indica que não houve). Esta nova coluna atua como um excelente indicativo de gravidade para modelos de classificação.
- **Tratamento de Valores Ausentes (NaNs):**
  - **Remoção Direcionada:** Registros que continham nulos em colunas fundamentais para a coerência clínica e demográfica (como Escolaridade, Via de Exposição, Circunstância, Agente Tóxico e Evolução) foram removidos do *dataset*.
  - **Preenchimento Estratégico:** Para evitar perda massiva de dados, variáveis com alta taxa de valores faltantes que não invalidavam a notificação (como Situação de Trabalho) tiveram seus nulos preenchidos com o valor neutro "Ignorado"ou seu equivalente numérico ("99.0"). A coluna `DT_OBITO` foi desconsiderada na filtragem por apresentar mais de 99% de nulos.

Após todo o fluxo de processamento, o *dataset* final restou com 449.986 instâncias limpas, estruturadas e prontas para a geração de *insights* estatísticos.

4 Análise Exploratória de Dados (EDA)

Com os dados limpos, iniciamos a exploração visual para identificar padrões epidemiológicos, correlações e o perfil das vítimas de intoxicação exógena, bem como fatores cruciais como o tempo de atendimento.

4.1 Evolução Temporal e Distribuição mensal

Permite que analisemos o volume de casos em cada ano e como esses casos estão distribuídos ao longo do ano.

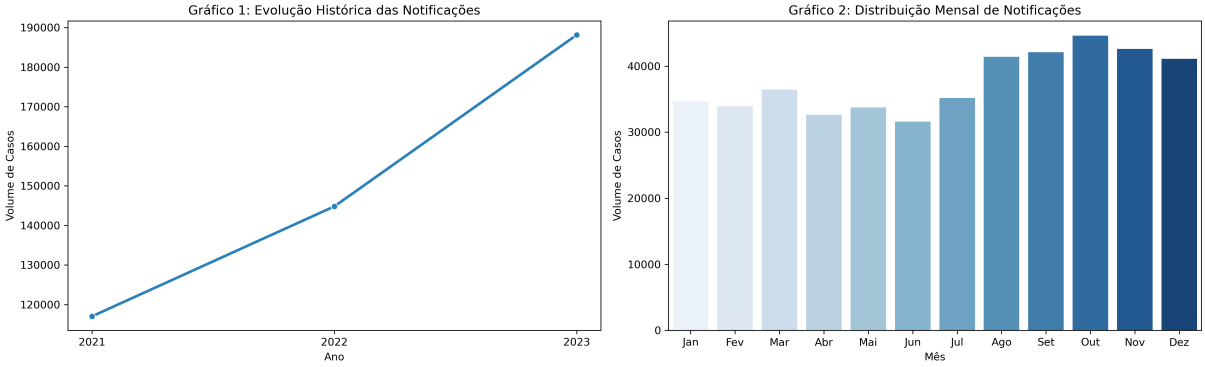

Figura 1: À esquerda: Evolução das Notificações (2021-2023). À direita: Distribuição mensal

O Gráfico 1 evidencia o volume de casos notificados ao longo dos anos analisados, permitindo visualizar a tendência de crescimento das notificações de 2021 a 2023. O Gráfico 2 mostra a distribuição dessas notificações, mostrando que no final do ano temos mais casos que no começo, mas nada muito significativo.

4.2 Distribuição de idade por sexo e pefil étnico/racial

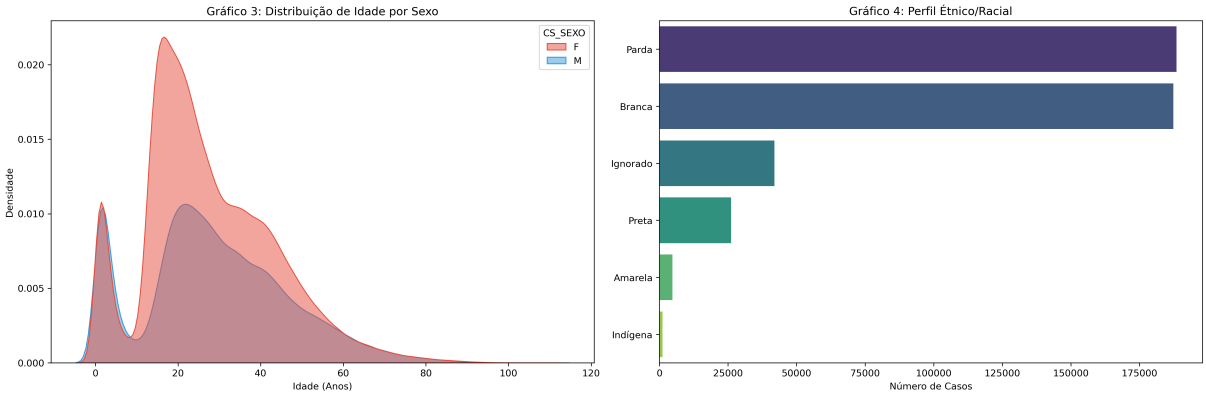

Figura 2: À esquerda: Distribuição idade por sexo. À direita: Perfil Étnico Racial.

O Gráfico 3 mostra que o número de mulheres é maior, justificado pelo fato de haver mais mulheres que homens no Brasil e pelo fato das mulheres tenderem a procurar mais o hospital, mas que a distribuição de acordo com a idade não muda, tendo um pico na infância e outro pico na faixa dos 20 anos. Já o Gráfico 4, mostra um imenso domínio da raça parda e branca no dataset.

4.3 Locais de Exposição

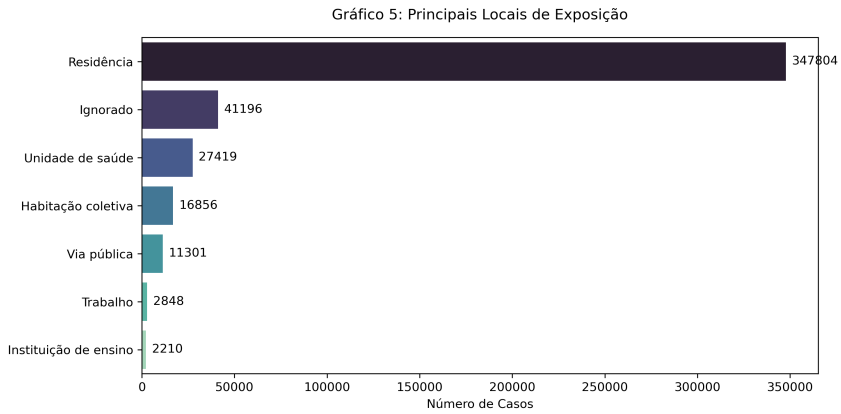

Figura 3: Evolução dos Casos por Gênero ao Longo dos Anos

O gráfico 5 mostra que há quase um domínio de casos em que o local de exposição foi a residência da pessoa.

4.4 Agente tóxico vs Circustância

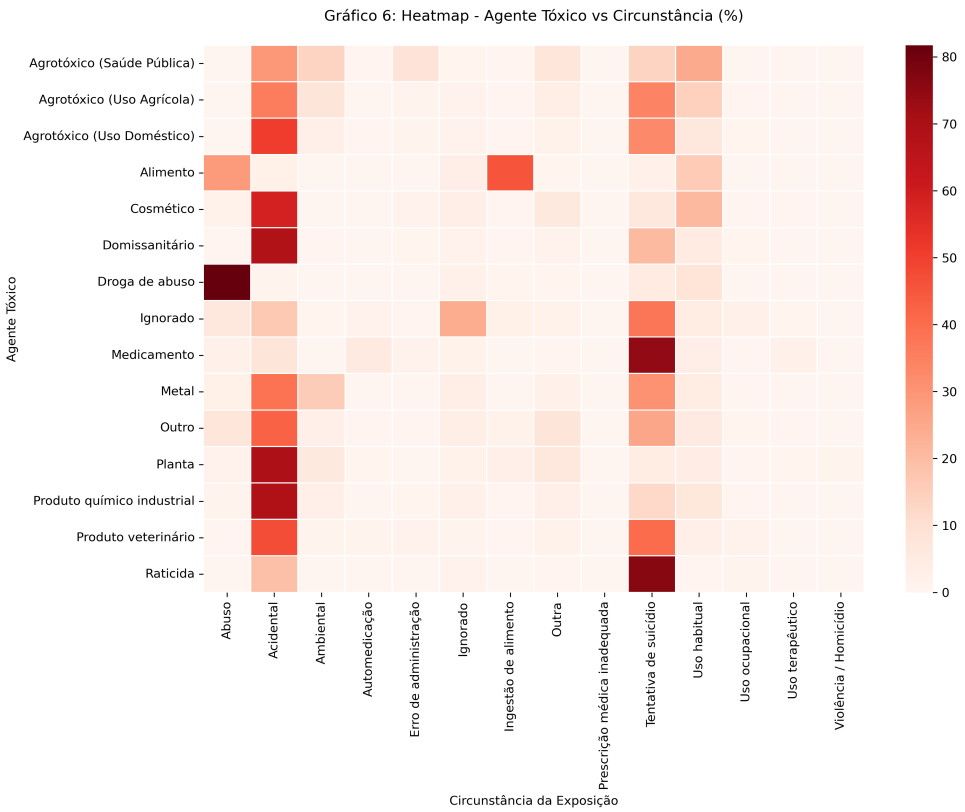

Figura 4: Heatmap Agente Tóxico VS Circunstância

Pelo Gráfico 6 conseguimos visualizar algumas relações, como por exemplo, quando a intoxicação é por agrotóxicos ou produtos industriais, normalmente a intoxicação foi acidental. Todavia, quando o agente é medicamentos ou raticidas, normalmente a intoxicação aconteceu com a objetivo de tirar a própria vida.

4.5 Internação vs via de exposição

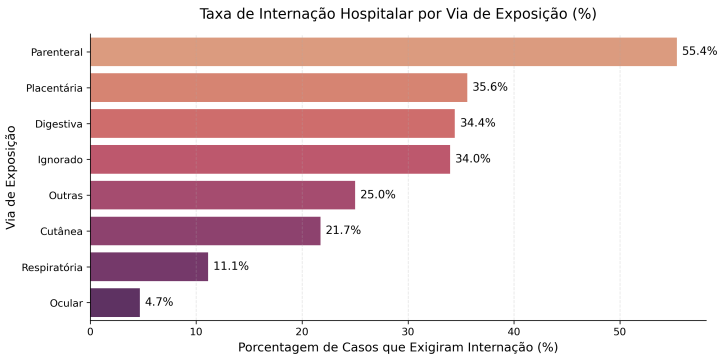

Figura 5: Taxa de internação vs via de exposição

Pelo Gráfico 7 conseguimos perceber que quando a via de exposição é parenteral, maiores as chances de internação, devido ao pelo fato da toxina agir mais rápido ao ser inserida

diretamente no sangue e não passar pelo estômago. A via placentária tem um bom número de internações, pelo fato de que o recém-nascido ainda não possui uma boa imunidade.

4.6 Taxa de Letalidade por Agente

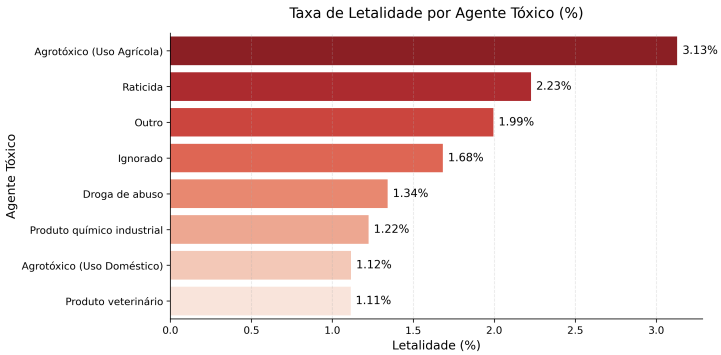

Figura 6: Taxa de letalidade por agente

Podemos notar que agrotóxicos e raticidas são os agentes com maior taxa de letalidade, porém não são os principais em óbitos absolutos (próxima figura). Isso se deve, principalmente, pelo acesso mais restrito à maior parte da população.

4.7 Volume absoluto de óbitos

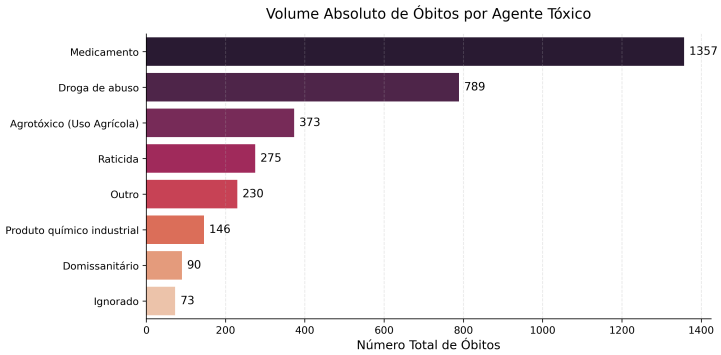

Figura 7: Volume de óbitos por agente

Aqui podemos ver exatamente quais são os agentes mais "perigosos", não por sua taxa de letalidade (figura anterior), mas sim pela facilidade ao acesso destes agentes, que são em maior parte medicamentos e drogas.

5 Conclusão Parcial

A etapa de exploração, análise e pré-processamento atingiu seu objetivo principal: transformar um conjunto de dados brutos e com ruídos do SINAN em uma base estruturada, limpa e com representatividade clínica, consolidando 449.986 registros válidos. O rigoroso tratamento de inconsistências e a engenharia de *features*, em especial a criação da

variável-alvo binária indicando a necessidade de internação, garantiram a qualidade e a consistência necessárias para a próxima fase do projeto.

Além da preparação técnica, a Análise Exploratória de Dados (EDA) revelou padrões epidemiológicos cruciais que guiarão a modelagem preditiva:

- **Perfil Demográfico:** Há uma predominância de casos entre mulheres, com picos de ocorrência durante a infância e na faixa dos 20 anos, concentrando-se majoritariamente nas populações parda e branca.
- **Contexto da Exposição:** O ambiente doméstico é o local de maior risco. Notou-se uma forte correlação comportamental entre o agente tóxico e a circunstância da exposição, onde medicamentos e raticidas estão frequentemente associados a episódios de lesão autoprovocada, enquanto agrotóxicos e produtos industriais estão majoritariamente ligados a acidentes.
- **Gravidade e Desfecho Clínico:** As vias de exposição parenteral e placentária resultam nas maiores taxas de internação. No que diz respeito à letalidade, os agrotóxicos e raticidas destacam-se como os agentes mais fatais. Contudo, os agentes responsáveis pelo maior número de óbitos são os medicamentos, devido à facilidade no acesso.

Com o mapeamento dessas correlações e a base de dados devidamente tratada, o projeto encontra-se pronto para a aplicação de algoritmos de aprendizado de máquina. Os *insights* obtidos suportam a viabilidade de treinar modelos de classificação capazes de prever a gravidade e o desfecho das intoxicações, contribuindo para a formulação de estratégias de triagem e resposta rápida em saúde pública.